


$$\begin{cases} u_t = -\Delta u & \Omega \times [0, T] \\ u(x, 0) = u_0(x) & \Omega \end{cases}$$

$$\begin{matrix} u_t \\ t_1 \\ \vdots \\ t_n \end{matrix} \begin{bmatrix} u_t(x_1, t_1) \\ \vdots \\ u_t(x_n, t_1) \\ \vdots \\ u_t(x_1, t_n) \\ \vdots \\ u_t(x_n, t_n) \end{bmatrix} = \begin{matrix} x & u & u_x & u_{xx} \dots \\ \begin{bmatrix} x_1 \\ \vdots \\ x_n \end{bmatrix} & \begin{bmatrix} u_1 \\ \vdots \\ u_n \end{bmatrix} & \begin{bmatrix} u_{x1} \\ \vdots \\ u_{xn} \end{bmatrix} & \dots \end{matrix} \begin{bmatrix} \text{coefficient} \end{bmatrix}$$

$b \quad A \quad x$

Challenges

- 1) 空间中每点放传感器 (sensor) 不现实, 代价太高
- 2) 对于一些很平滑的轨迹, 数据用得越多, A 就越可能病态



常系数偏微分方程

用 DFT, 则无需计算 $u_x, u_{xx} \dots$

$$\begin{bmatrix} u_t(x_1, \tau) \\ \vdots \\ u_t(x_s, \tau) \end{bmatrix} = \begin{bmatrix} x & u & u_x & \dots \end{bmatrix} \begin{bmatrix} \text{coefficient} \end{bmatrix}$$

★ 不同微分算子 (Δ) + 初始数据 $\implies \mathcal{L}$

- 1) data space 有多大 (放多少个 sensor 才能正确刻画 A)
- 2) data selecting strategy (在哪些地方放 sensor)

chap 2 强椭圆微分算子 ($|\log \varepsilon|^2$)

存在线性空间 $V \subset L^2(\Omega)$, 维度 $C|\log \varepsilon|^2$, 使得

$$\|u(\cdot, t) - P_V u(\cdot, t)\| \in C_2 \varepsilon \|u_0\|, \forall t \in [0, T]$$

- 一阶双曲微分算子

$$\begin{cases} u_t + \vec{c} \cdot \nabla u = 0 \\ u(x, 0) = u_0(x) \end{cases}$$

初始数据对解的影响很大, u_0

$$\int_0^T \|u(\cdot, t) - P_{V_k} u(\cdot, t)\|_{L^2(\Omega)}^2 dt = \int_{\Omega} \|u(x, \cdot) - P_{V_k} u(x, \cdot)\|_{L^2[0, T]}^2 dx = \sum_{j=k+1}^{\infty} \lambda_j \sim O(k^{-p})$$

u_0 正则性越差 (越不光滑), 越包含更多 Fourier mode, 解越容易识别

$$|<(x, y) := \int_0^T \int_{\Omega} u(x, s) u(y, s) ds, (x, y) \in \Omega^2, (s, t) := \int_{\Omega} u(x, t) u(x, s) dx, (s, t) \in [0, T]^2$$

对称半正紧积分算子 symmetric semi-positive compact integral operator 有相同特征值.

V_k^k 由 $|<(x, y)$ 前 k 个特征函数张成的空间, $V_G^k, \vec{c}(x) \in C^p(\Omega)$

chap 3 Identifiability & Stability

给出了常系数偏微分方程的解的稳定性, DFT解法

$$\text{给出了 } \|u(x, t) - \tilde{u}(x, t)\|_{L^2(\Omega \times [0, T])}^2$$

Remark:

$P_V u \sim u$ 是可行的; 初始数据 + L 的特性对解出 L 有较大影响.

Chap 4

Consistent and Sparse Local Regression. (CaSLR)

$$u_t = \sum_{k=1}^K C_k(x, t) f_k(x, t) \quad \hat{C}_j = (\hat{C}_1^j, \dots, \hat{C}_K^j)$$


candidate function.

$$\begin{aligned} \text{估计} \quad \mathcal{E}_{loc}^j(\hat{C}_j) &= \sum_{(x_{jm}, t_{jm}) \in \Omega_j} \left(u_t(x_{jm}, t_{jm}) - \sum_{k=1}^K \hat{C}_k^j f_k(x_{jm}, t_{jm}) \right)^2 \\ \mathcal{E}(\hat{C}) &= \sum_j \mathcal{E}_{loc}^j(\hat{C}_j), \quad \hat{C} = (\hat{C}_1, \dots, \hat{C}_J) \end{aligned}$$

$$\hat{C}^l = \arg \min_{\hat{C}} \mathcal{E}(\hat{C})$$

$$\text{subject to: } \|(\|\tilde{C}_1\|, \dots, \|\tilde{C}_K\|)\|_0 = l$$

$$\tilde{C}_k = (\hat{C}_k^1, \dots, \hat{C}_k^J)$$



$$S^l := \mathcal{E}(\hat{C}^l) + \rho \frac{1}{K} \rightarrow \text{dictionary 的大小}$$

$$\downarrow$$

$$\text{找 } S^{l^*} = \min_{l=1, \dots, K} S^l$$

4.2 理论分析上述做法的可行性

定义了 K_B^p 解的条件数, $B \subset \Omega$, p 表在 $L^p(\Omega)$ 空间中.

对于常数偏微算子, 若 $K_B^2 > 0$, 则是有解, 且稳定的.

↓ + 线性微分算子, 初始条件有更多的 Fourier mode
变系数, 也有同样的结果.

4.3 提供筛选数据的办法

$$\beta(x_j, t_j) = \sqrt{\frac{1}{n} \sum_{m=1}^{m_j} \sum_{p=1}^{p_{\max}} (\partial_x^p u(x_{j,m}, t_{j,m}))^2}$$

(无干扰)
只要在 $[\underline{\beta}, \bar{\beta}]$ 中的
数据.

(高斯干扰下如何选择)